Ecole Polytechnique de l'Université François Rabelais de Tours
Spécialité Informatique
64 avenue Jean Portalis
37200 Tours, France
Tél. +33 (0)2 47 36 14 14
www.polytech.univ-tours.fr

Projet Libre 2019

-

Visualisation de la base de données complexe

Tuteurs académiques
Gilles VENTURINI

Étudiants
Alafate ABULIMITI (DI5)
Yuanyuan LI (DI5)

Table des matières

1 Introduction

La visualisation des données est un domaine très important dans le domaine de la science des données et une méthode couramment utilisée en science de la décision. Dans ce projet, nous (Alafate ABULIMITI et Yuanyuan LI) utiliserons la méthode décrite dans cet article (On visualizing large multidimensional datasets with a multi-threaded radial approach) pour visualiser la base de données "Open Food Fact".

2 Description générale

Nous allons utiliser les outils ci-dessous pour visualiser la base de données comme décrit dans l'article.
Dans ce projet, nous avons utilisé **Python** comme langage de développement.

Python

Parce que ce langage a une extension forte et dispose d'une riche bibliothèque d'outils de visualisation et de science des données.

Pandas en tant que bibliothèque de traitement et de nettoyage des données intègrent un grand nombre de bibliothèques et certains modèles de données standard, fournissant les outils nécessaires pour manipuler efficacement de grands ensembles de données. Pandas fournit un certain nombre de fonctions et de méthodes qui nous permettent de traiter les données rapidement et facilement.

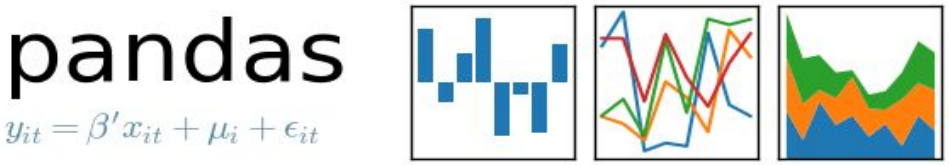

Pandas

Nous utilisons **Matplotlib** comme notre bibliothèque pour la visualisation de données. Matplotlib est une bibliothèque de dessins 2D Python qui produit des graphiques de niveau qualité de publication dans une variété de formats de copie papier et d'environnements interactifs multi plates-formes.

Avec Matplotlib, les développeurs peuvent générer des tracés, des histogrammes, des spectres de puissance, des graphiques à barres, des tracés d'erreur, des diagrammes de dispersion, etc. avec seulement quelques lignes de code.

Matplotlib

Nous rencontrons des problèmes avec matplotlib, notamment:
1. Mauvaise interactivité: il ne peut y avoir d'expérience interactive fluide, telle que le zoom avant et arrière.
2. Le dessin est lent, même si vous utilisez la méthode parallèle. La vitesse est incrémentée du nombre de points.
Pour ces deux raisons, nous avons remplacé nos outils de dessin.

Nous avons utilisé l'outil **Plotly**. La bibliothèque graphique de Python de Plotly permet de créer en ligne des graphiques interactifs de qualité publication, tels que des tracés linéaires, des diagrammes de dispersion, des graphiques en aires, des graphiques à barres, des barres d'erreur, des diagrammes à barres, des histogrammes, des cartes sous-graphiques, des graphiques à axes multiples, des graphiques polaires, etc. Diagrammes à bulles.

Plotly

3 Analyse et conception

3.1. OpenFood

Open Food Facts est une base de données de produits alimentaires qui répertorie les ingrédients, les allergènes, la composition nutritionnelle et toutes les informations présentes sur les étiquettes des aliments.

Open Food Facts est une association à but non lucratif composée de volontaires.
Plus de 9000 contributeurs comme vous ont ajouté 600 000 produits de 200 pays en utilisant notre app Android, iPhone ou Windows Phone ou leur appareil photo pour scanner les codes barres et envoyer des photos des produits et de leurs étiquettes.

Les données sur la nourriture sont d'intérêt public et doivent être libres et ouvertes. Toute la base de données est publiée sous forme de données ouvertes (open data) qui peuvent être utilisées par tous et pour tous usages

La description spécifique des données est la suivante:
https://world.openfoodfacts.org/data/data-fields.txt.

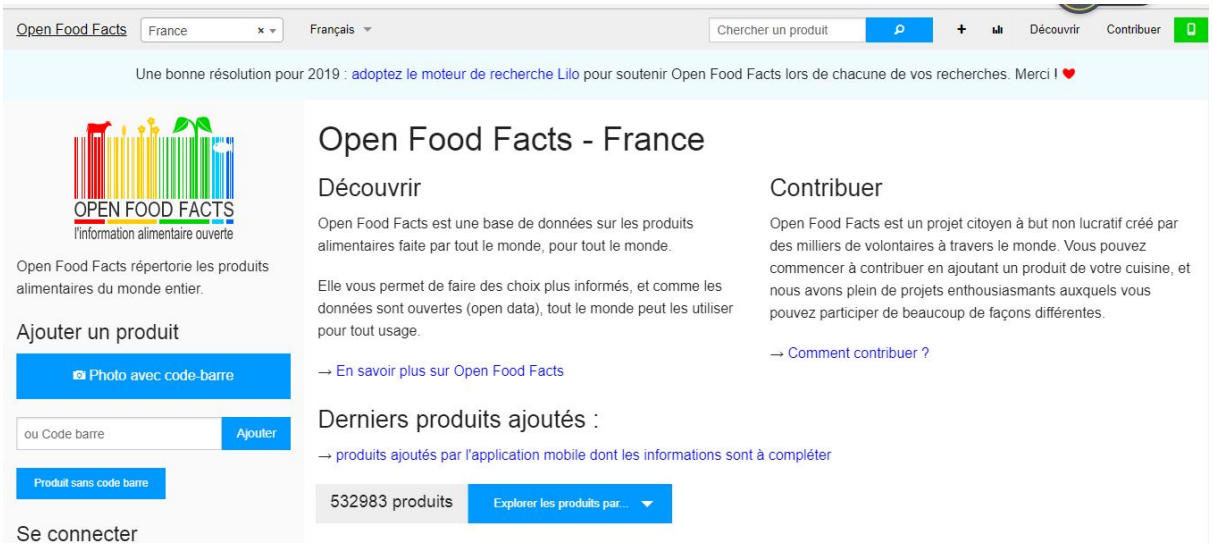

OpenFood WebSite

Ces données peuvent être grossièrement divisées en deux types: **types numériques et types de texte.**

3.2. Choix de techenique

3.2.1. Controleur de version du projet

Nous gérons la version de notre projet par 'Git'. Et pour chaque version d'implémentation, on crée une branche (2 branches totales, comme l'image ci-dessous).

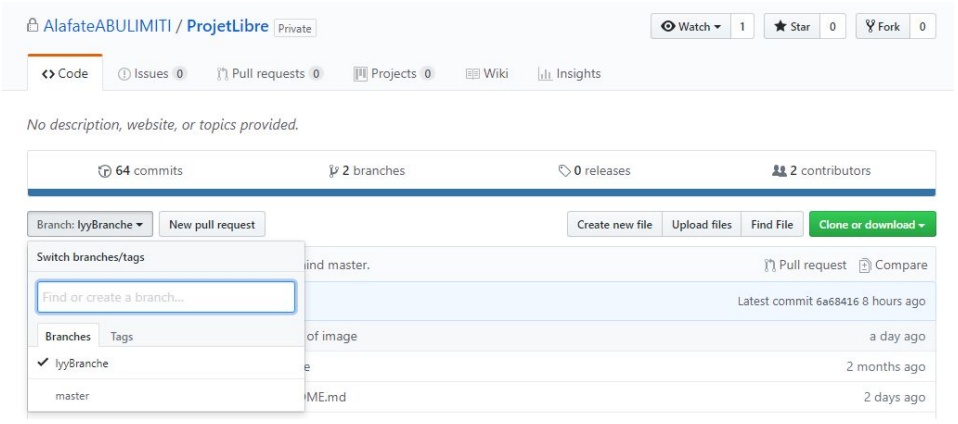

Git

3.2.2. Etat de l'art

Notre tâche principale est de mettre en œuvre la méthode de visualisation des données dans cet article: On visualizing large multidimensional datasets with a multi-threaded radial approach.

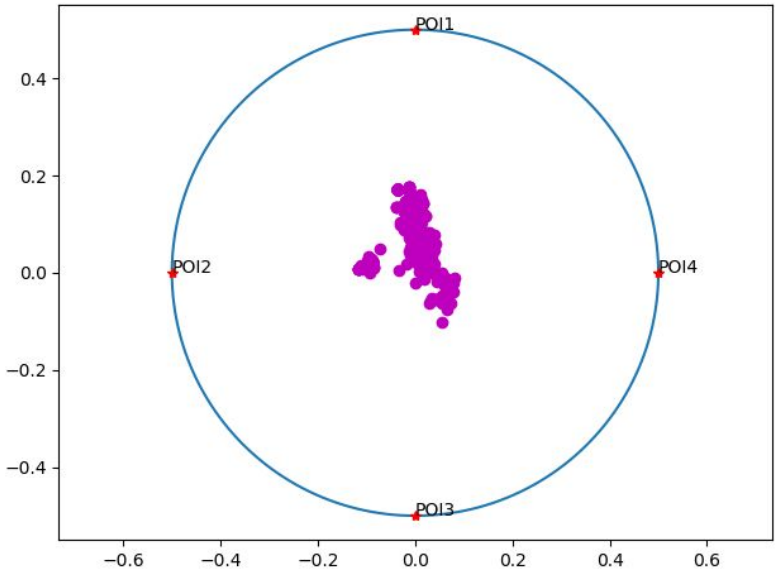

Les étapes de visualisation des données de ce document sont les suivantes:
1. Le point de données sélectionné est utilisé comme point d'intérêt.
2. Calculer la distance entre les autres points et les points d'intérêt.
3. Calculer les coordonnées du point.
4. Visualiser les données comme indiqué.

3.2.3. La methodé 2-Gram

Pour les données de deux types de texte, nous ne pouvons pas déduire directement leur distance directe. Nous devons d'abord vectoriser les données de texte.

Nous avons besoin d'une méthode 2-grams pour la vectorisation du texte. La méthode spécifique est la suivante:
1. Épissage des données de type texte
2. Séparer les données toutes les deux lettres
3. Compter le nombre d'occurrences de deux combinaisons de lettres
4. Placer dans un vecteur 26 * 26.

Exemple : tu es beau

	aa	ab	...	au	...	be	...	es	...	tu	...	zy	zz
tu es beau	0	0	...	1	...	1		1		1		0	0
...													

Dans cet exemple, nous divisons cette phrase en quatre parties: tu es beau.Pour le vecteur 26 * 26, nous pouvons en placer 1 pour les colonnes au, be, es, tu. Ceci représente une occurrence.

4 Mise en oeuvre

4.1. Présentation de données

Le fichier (‘.csv’) de Open Food données est très grand (755252 lignes, 173 colonnes, la mémoire est plus de 2 GB). Donc, nous d’abord récupérons une partie de ces données pour visualiser et traiter facilement (aussi pour tester). Une partie de données est comme l’image ci-dessous:

code	url	creator	created_t	created_d	last_modi	last_modi	product_name	generic_n	quantity	packaging
17	http://worl	kiliweb	1529059080	2018-06-15T	1529059204	2018-06-15T	Vitôria crackers			
123	http://worl	kiliweb	1535737982	2018-08-31T	1535737986	2018-08-31T	Sauce Sweety chili 0%			
178	http://worl	kiliweb	1542456332	2018-11-17T	1542456333	2018-11-17T	Mini coco			
949	http://worl	kiliweb	1523440813	2018-04-11T	1546194697	2018-12-30T	Salade de carottes râpées			
970	http://worl	kiliweb	1520506368	2018-03-08T	1520506371	2018-03-08T	Fromage blanc aux myrtilles			
1137	http://worl	kiliweb	1539781575	2018-10-17T	1539781578	2018-10-17T	Baguette parisien			
1151	http://worl	kiliweb	1537883404	2018-09-25T	1537883538	2018-09-25T	"Baguette Lyonnais"			
1199	http://worl	kiliweb	1517833594	2018-02-05T	1540674511	2018-10-27T	Solène céréales poulet			
1281	http://worl	kiliweb	1517830801	2018-02-05T	1527070794	2018-05-23T	Tarte noix de coco			barquette,p
1311	http://worl	kiliweb	1520419800	2018-03-07T	1520419813	2018-03-07T	Salade de fruits exotiques			
1328	http://worl	kiliweb	1532982378	2018-07-30T	1547019955	2019-01-09T	Chouquettes x 30			
1564	http://worl	kiliweb	1523443867	2018-04-11T	1523443872	2018-04-11T	Fromage blanc pêche			
1663	http://worl	kiliweb	1509478049	2017-10-31T	1509478053	2017-10-31T	Crème dessert chocolat			
1885	http://worl	kiliweb	1511180337	2017-11-20T	1518126491	2018-02-08T	Compote de poire			
2042	http://worl	kiliweb	1523528250	2018-04-12T	1523528261	2018-04-12T	Paëlla de poulet			
2219	http://worl	kiliweb	1522840946	2018-04-04T	1522840950	2018-04-04T	Salade shaker chef			
2257	http://worl	kiliweb	1520506122	2018-03-08T	1520506124	2018-03-08T	Salade de macedoine de légumes			
2264	http://worl	kiliweb	1518439960	2018-02-12T	1518439971	2018-02-12T	Baguette Poitevin			
2363	http://worl	kiliweb	1539603306	2018-10-15T	1539603411	2018-10-15T	Suedois thon			
2400	http://worl	kiliweb	1520248076	2018-03-05T	1520248080	2018-03-05T	Ciabatta Bombay			
2417	http://worl	kiliweb	1521725615	2018-03-22T	1521725617	2018-03-22T	Ciabatta Roma			
3018	http://worl	kiliweb	1538739046	2018-10-05T	1538739049	2018-10-05T	Salade tomate			
3384	http://worl	kiliweb	1520597206	2018-03-09T	1520597247	2018-03-09T	Mousse chocolat douceur			

openfood csv fichier (une partie - 500 lignes)

Il contient 173 colonnes et 500 lignes. c’est à dire, pour chaque produit, on peut utiliser 173 attributs pour le décrire. Parce que ce fichier contient beaucoup d'informations qui ne sont pas très importantes. En plus, certaines descriptions d'informations sont confuses et le format n'est pas uniforme, par exemple, sur la colonne ‘brand’.Et ‘Auchan’ et ‘auchan’ sont des description de la marque ‘Auchan’. En conséquence, on doit d’abord nettoyer ces données.

4.2. Traitement de données

4.2.1.Choix d'attributs

Pour visualiser les données,d'abord on doit déterminer avec quelles attributs on analyse.
Le critère de choix d'attributs: l'attribut représentatif et important, aussi, si dans une colonne, il n'y a pas beaucoup de contenus, on ne choisit pas cet attribut non plus.

colonnes
url
product_name
brands
categories_fr
labels
allergens_fr
traces_fr
additives_n
additives_fr
main_category_fr
image_small_url
energy_100g
fat_100g
saturated-fat_100g
carbohydrates_100g
sugars_100g
fiber_100g
proteins_100g
salt_100g
sodium_100g

Choix de attributs (colonnes)

Les attributs principaux:

- url: l'url de produit.
- product_name: le nom de produit.
- brands: la marque de produit.
- categories_fr: la categorie de produit.
- additives: l'additif de l'alimentation.
- protein: le pourcentage de la protéine.

4.2.2. Prétraitement de attributs

1. Nous divisons ces attribut à 3 groupes:

- **Groupe 1**: ces attributs peuvent être utilisées comme le label.

types	colonnes
Label	url
Label	product_name
Label	brands
label	image_small_url

L'attribut comme le label

- **Groupe 2**: quand on calcule la similitude des produits, ces attributs peuvent être utilisées la méthode 2-gram à calculer.

types	colonnes
2-GRAM	categories_fr
2-GRAM	labels
2-GRAM	allergens_fr
2-GRAM	traces_fr
2-GRAM	additives_fr
2-GRAM	main_category_fr

L'attribut utilisant 2-gram à calculer

- **Groupe 3**: quand on calcule la similitude des produits, le contenu de ces attributs sont numériques, donc, nous pouvons utiliser la 'Distance Euclidienne' directement.

types	colonnes
NUM	additives_n
NUM	energy_100g
NUM	fat_100g
NUM	saturated-fat_100g
NUM	carbohydrates_100g
NUM	sugars_100g
I ou NUM	fiber_100g
NUM	proteins_100g
NUM	salt_100g
NUM	sodium_100g

L'attribut numerique

2. Traitement de l'attribut **'brands'**:

Nous observons la colonne 'brands', on trouve qu'il utilise plusieurs types de descriptions pour une marque, par exemple, en effet CROUS = Crous. En plus, quelques produits ont plusieurs marques labels.

brands
CROUS
Crous Resto',Crous
Ferme De La Frémondière
Crous
Crous resto
Crous
Crous
Torn & Glasser
Crous
Crous
Crousresto'
Grizzlies
Daddy's Muesli
Sunridge
Grizzlies
Grizzlies
Pcc
Sunridge
Sunridge

L'attribut 'brand'

Donc, nous voulons nettoyer cette colonne. Parce que le fichier complet est très grand, on juste récupère la colonne ‘brands’.
(1). D’abord, on utilise ‘OpenRefine’ pour diviser ces marques pour chaque lignes. Aussi, on remplit toutes les ligne Null avec le mot - ‘NoBrand’.

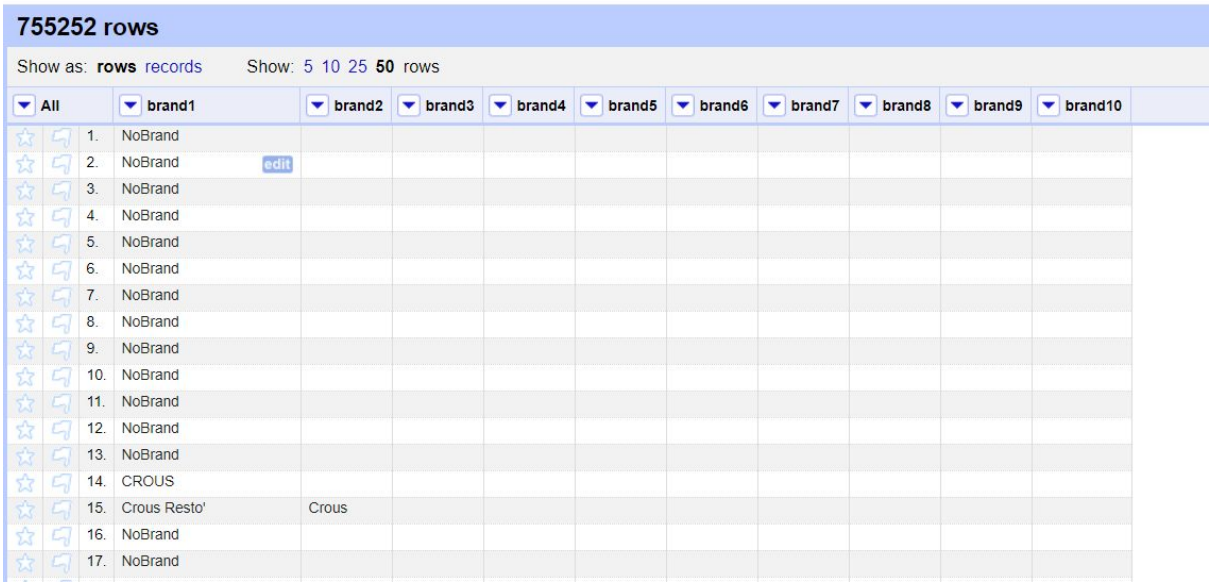

755252 rows

Show as: **rows** records Show: 5 10 25 **50** rows

All		brand1	brand2	brand3	brand4	brand5	brand6	brand7	brand8	brand9	brand10
	1.	NoBrand									
	2.	NoBrand edit									
	3.	NoBrand									
	4.	NoBrand									
	5.	NoBrand									
	6.	NoBrand									
	7.	NoBrand									
	8.	NoBrand									
	9.	NoBrand									
	10.	NoBrand									
	11.	NoBrand									
	12.	NoBrand									
	13.	NoBrand									
	14.	CROUS									
	15.	Crous Resto'	Crous								
	16.	NoBrand									
	17.	NoBrand									

La division de ‘brands’

(2).On juste utilise la première marque pour labelliser chaque produit. Et on veut utiliser la fonctionnalité ‘Facet’ et ‘Cluster’ de ‘OpenRefine’ pour nettoyer la colonne ‘brand1’. Mais, il y a plus de 90,000 types de descriptions, il a besoins beaucoup de mémoire pour exécuter et il a toujour crash en cours d'exécution. Donc, on utilise ‘Excel’ traitant avec ‘Top 10 des marques avec le plus de produits’.

marque	nombre
NoBrand	449097
Carrefour	3615
Auchan	2554
Nestlé	2035
Leader Price	1685
Coop	1491
Sans Marque	1393
Migros	1090
Casino	1060
u	990

Top 10 des marques avec le plus de produits

Après nettoyage:

brand1	Nombre
NoBrand	449097
Carrefour	3615
Auchan	2554
Nestlé	2035
Leader Price	1685
Coop	1491
Sans Marque	1393
Migros	1095
Casino	1066
U	991

Top 10 des marques avec le plus de produits - après nettoyage

Jusqu'à cette étape, on peut commencer à calculer la similitude entre des produits.
(1). D'abord, on choisit 5 produits par la méthode 'K-Means'. Ces 5 points sont comme Point d'intérêt, noté comme POIs

(2). Suivante, on calcule la similitude entre chaque point et POIs.

Nous allons calculer la distance entre les deux données en utilisant la distance euclidienne plus la similarité entre les mots. La formule correspondante est la suivante:

$$d(x,y) := \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2}$$

$$\text{similarity} = \cos(\theta) = \frac{A \cdot B}{\|A\|\|B\|} = \frac{\sum_{i=1}^{n} A_i \times B_i}{\sqrt{\sum_{i=1}^{n} (A_i)^2} \times \sqrt{\sum_{i=1}^{n} (B_i)^2}}$$

Mais ces deux valeurs ne sont pas sur une échelle et la distance euclidienne sera supérieure à la similarité. Nous devons donc le faire la pondération.

Une telle normalisation est propice à une discrimination accrue des deux données.

Distance = 0.2 * Distance numérique + 0.8 * （1-Similarite de texte）

Le nombre total de points (à calculer la coordonnée)	**Le nombre de processeurs**	**Le nombre de task**	**Le temps moyen pour chaque task**	**Le temps total moyen**
1,000	4	4	environs 1 minutes	environs 1 minutes

10,000	4	16	environs 2 minutes	environs 8 minutes
100,000	4	16	environs 22.5 minutes	environs 90 minutes
755,252	3	64	en virons 25 minutes	environs 8 heures
	40	160	environs 20 minutes	environs 1 heure

Le temps de calculer la coordonnée

4.3. Visualisation interactive

4.3.1. Version 1.0 - Matplotlib

Après on obtient les coordonnées pour chaque point, on peut positionner ces points sur l'image ou la figure.
Au début, nous utilisons la librairie 'Matplotlib' pour faire la visualisation, et on essaie avec 1000 points (4 POIs). Le résultat est comme l'image ci-dessous. Quand on clique sur un point, il affichera le label avec l'information de produit (le nom et la marque).

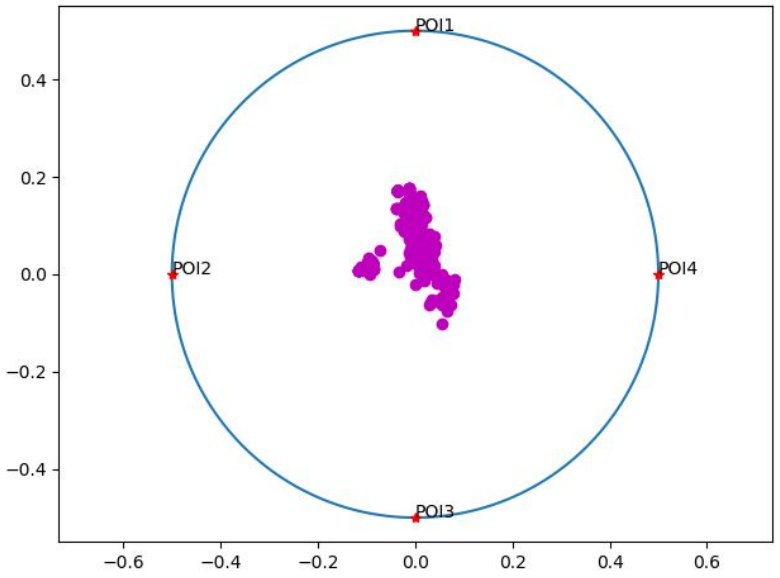

La visualisation avec 500 points (Matplotlib)

Quand on augmente le nombre de points, on trouve que le temps d'exécution augmente plus.

Le nombre total de points (à positionner)	**Le nombre de points (à positionner) augmenté**	**Le temps augmenté pour positionner (créer la figure)**	**Le temps total pour positionner (créer la figure)**

10,000	10000	2 minutes	2 minutes
20,000	10000	3 minutes	5 minutes
30,000	10000	5 minutes	10 minutes
40,000	10000	8 minutes	18 minutes
…...	…...	…….	…...
750,000	10000	…….	plus de 1 jour

Le temps pour créer *la figure- Matplotlib*

Vers ce tableau, nous pouvons observer que si on veut positionner 750,000 points sur la figure, ce prendra plus de 1 jour.
Et aussi, on teste avec tous les points (755252 points), on trouve qu'il ne peut pas afficher le résultat de la figure dans 1 heure. Donc, nous changeons la libraire pour faire la visualisation.

4.2.2. Version 2.0 - Plotly.Scatter

La libraire 'Plotly' permet de créer de figures, diagrammes, images, etc. Aussi, il a une variété de fonctionnalités interactives, par exemple: zoomer, afficher le label, afficher la légende. Et il peut sauvegarder tous les donnees de figures dans un fichier '.html'.
Nous ajoutons la légende avec 'Top 5 des marques avec le plus de produits', le type de la figure est 'SVG'.

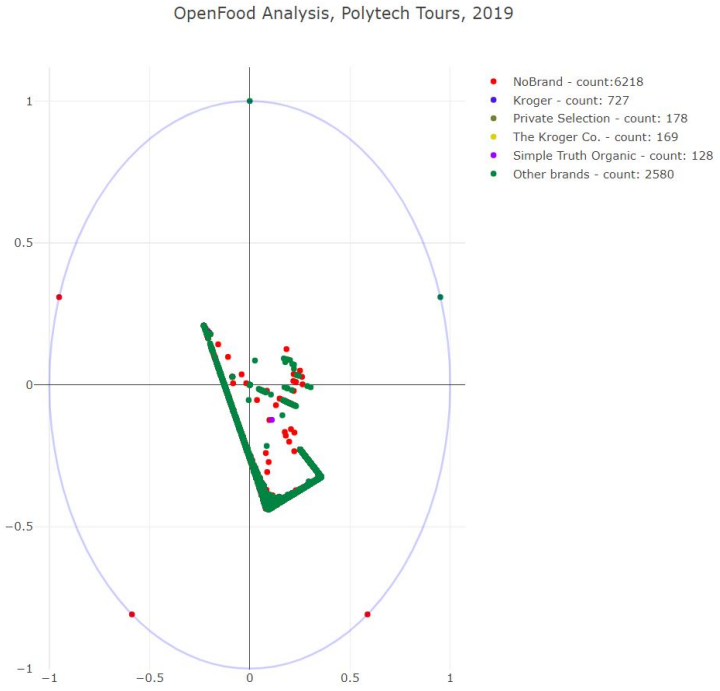

La visualisation avec 10000 points (Plotly.Scatter)

Et le temps d'exécution est plus court, on teste avec tous les points (755252 points), il juste prend 40 seconds (comme l'image ci-dessous).

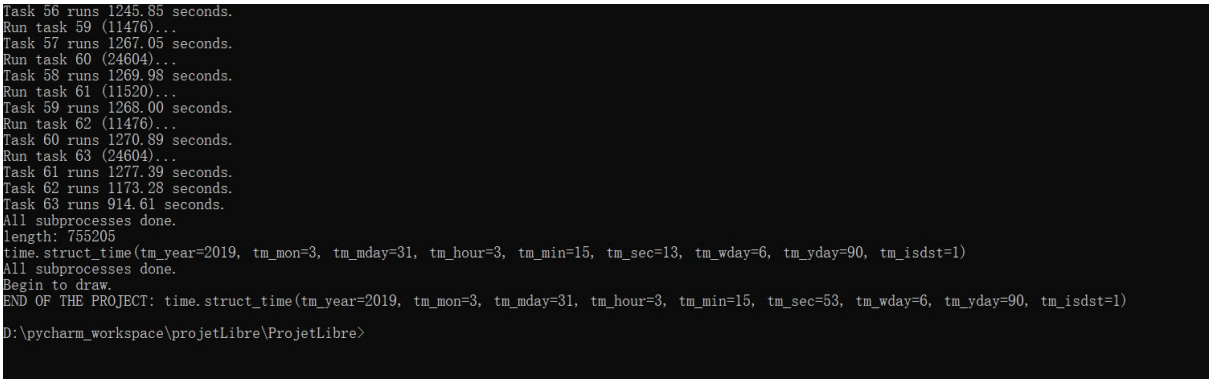

Le temps pour créer *la visualisation - Plotly.Scatter*

Mais, on trouve l'autre problème, la charge du fichier '.html' et le rendu de l'image nécessitent pleines ressources de navigateur. Donc, quand on charge le fichier '.html' (le résultat de la visualisation), si le nombre de points plus grande, le temps d'affiche sera plus long.
Aussi, quand on clique sur l'image, il peut être apparaît le crash. Et on essaie avec plusieur navigateurs, le résultat est comme le tableau ci-dessous:

Le nombre total de points (à positionner)	**Le navigateur**	**Le temps d'affiche**	**Crash ou non**
1,000	Chrome	moins de 5 seconds	Non
10,000	Chrome	moins de 5 seconds	Non
100,000	Chrome	plus de 5 seconds	Crash beaucoup
755,252	Chrome	ne peut pas affichier	/
	FireFox	ne peut pas affichier	/
	IE	ne peut pas affichier	/
	Microsoft Edge	plus de 15 seconds	ne peut pas etre interactif

Le temps d'affichier la figure 'SVG'

Vers le tableau ci-dessous, on peut trouver qu'il ne peut pas afficher la figure dans le navigateur. Donc, nous voulons utiliser d'autre type de l'image pour afficher le résultat.

4.2.3. Version 3.0 - Plotly.Scattergl

Quand on lit API de la libraire 'Plotly', on trouve l'autre type de l'image 'WebGL' qui permet d'afficher millions points. Donc, on change le type de la figure, et on relance notre projet.

Le nombre total de points (à positionner)	**Le navigateur**	**Le temps d'affiche**	**Crash ou non**

1,000	Chrome	moins de 3 seconds	Non
10,000	Chrome	moins de 3 seconds	Non
100,000	Chrome	moins de 5 seconds	Non
755,252	Chrome	moins de 5 seconds	Non

Le temps d'affichier la figure 'WebGL'

4.4. Analyse de résultats

4.4.1. Visualisation de résultats

(1). Visualiser avec 10000 points

Vers l'image ci-dessous, on peut regarder la titre de la figure, la légende de la figure. Aussi, on peut savoir que dans ces 10000 points, les marques qui ont des plus produits sont: 'Kroger', 'Private Selection', 'The Kroger Co.' et 'Simple Truth Organic'.

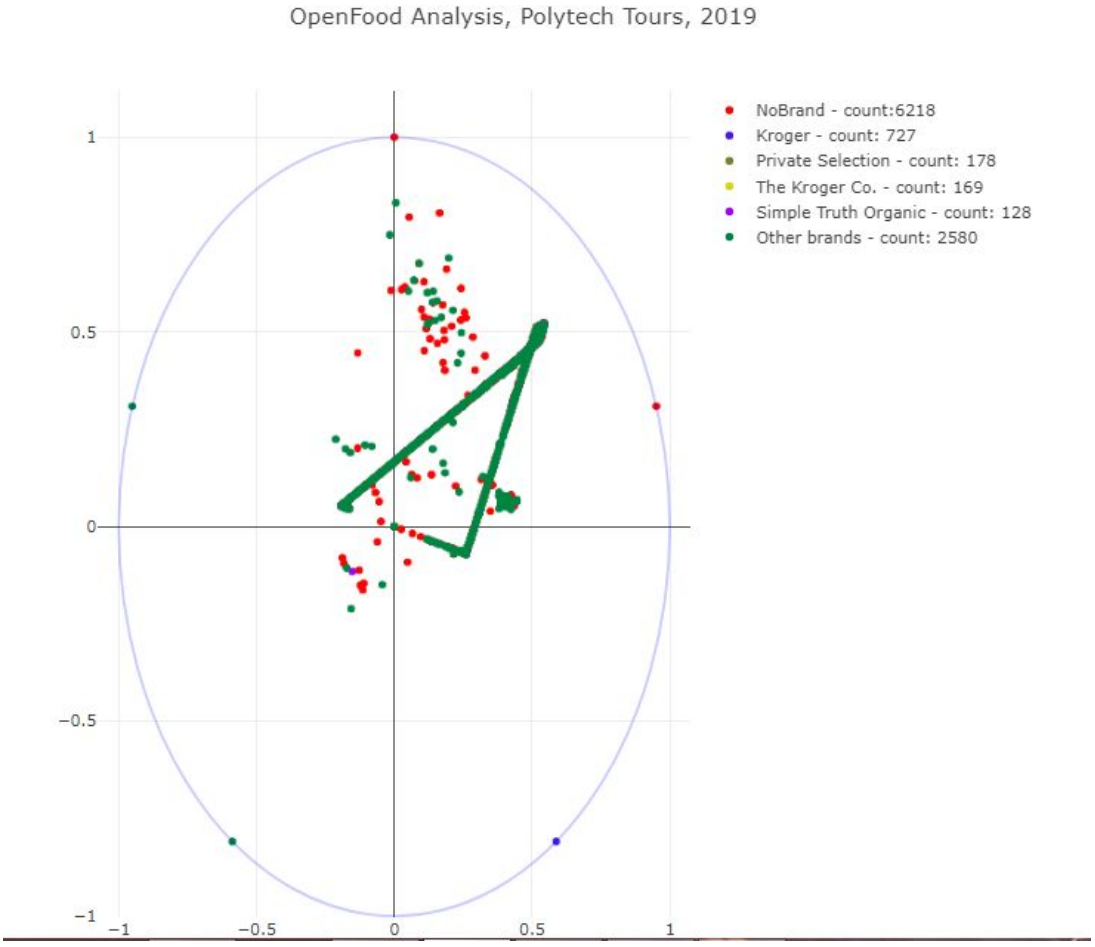

La visualisation avec 10000 points

Au-dessus de la figure, il y a plusieurs fonctionnalités interactives: par exemple, sauvegarder la figure comme une l'image au format 'PNG', zoomer + ou -,

Les fonctionnalites interactives

Nous pouvons choisir quelque région pour grandir, et quand on met la souris sur un point, il affichera la coordonnée de ce point, le nom de produit et la marque de produit (comme l'image ci-dessous).

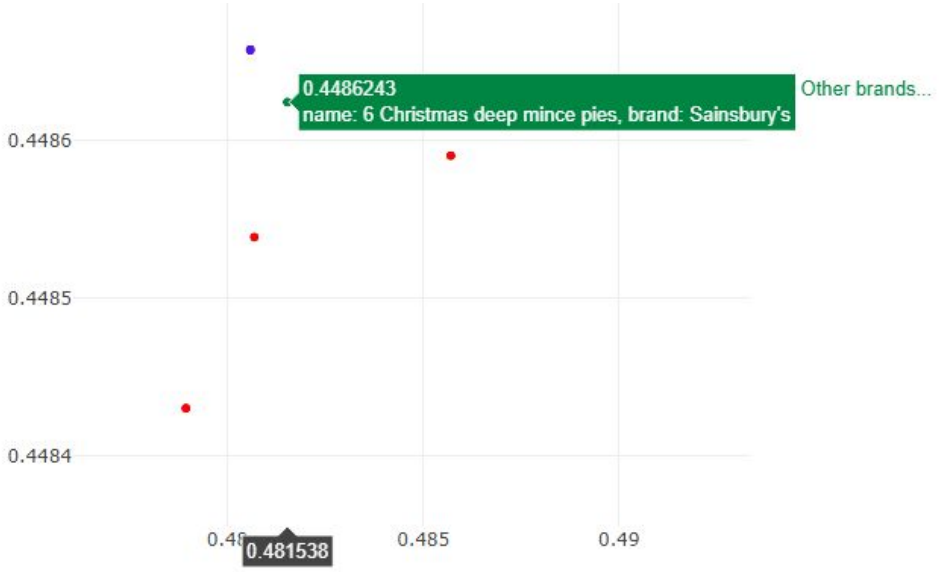

Zoomer et affichier l'information d'un point

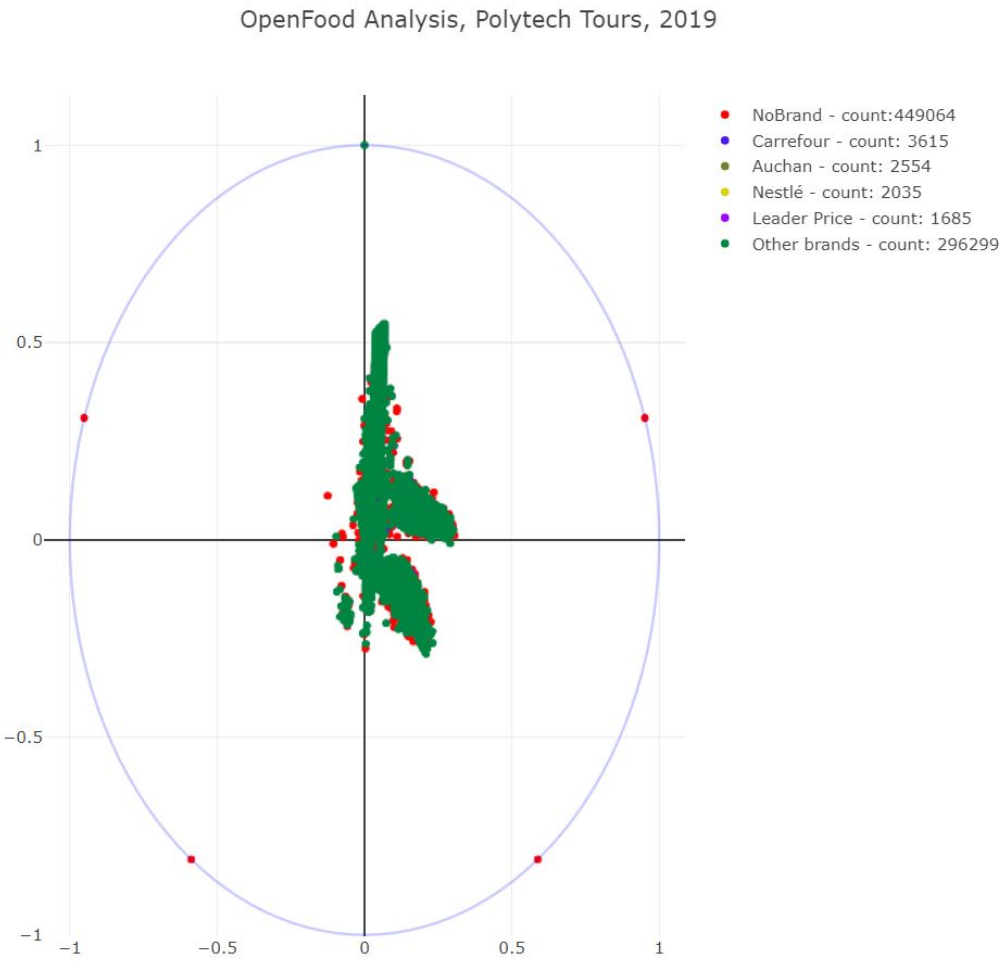

La visualisation avec 755,252 points

4.4.2. La performance et la qualité

Le temps d'éxecution totale est comme le tableau ci-dessous:

Le nombre de points	**Le nombre de processeurs**	**Le temps d'éxecution total (moyen)**
100	4	moins de 1 minute
1,000	4	moins de 5 minutes
10,000	4	9 minutes
100,000	3	90 minutes
755,252	3	8 heures
	40	environs 1 heure

Le tableau de temps d'execution total

5 Bilan et conclusion

5.1. Faits

Pendant notre projet libre, notre faits sont comme ci-dessous:

- Récuperer et prétraiter les donnees de websit ‘OpenFood’.
- Lire et etudier le document de la visualisation.
- Calculer la distance (la similitude) entre des produits (multi processus, 755,252 produits).
- Réaliser la visualisation interactive (WebGl, 755,252 points).
- Ecrire le rapport.
- Preparer tous les document et code pour la soutenance.

5.2.Reste à faire

Parce que nous juste formalisons les description de quelques marques. Donc, pour plus loin, nous pouvons formaliser et nettoyer toutes les descriptions de marques.

5.3. Bilan auto-critique

Pendant le projet libre, nous avons revisé et étudié des connaissances et des méthodes des traitement de données, par exemple, la méthode ‘2-Gram’. Aussi, on a révisé et étudié des outils pour traiter ou nettoyer les données, par exemple, ‘Excel’, ‘OpenRefine’.
En plus, nous avons étudié les libraires pour visualiser les données, par exemple, la librairie ‘Matplotlib’, la libraire ‘Plotly’.
Vers ce projet, nous avons aussi étudié qu’il important de chercher et choisir les techniques pour programme. Par exemple, bien que la figure ‘SVG’ satisfait 10000 points, il ne peut pas bien être chargé avec 10000 points ou plus.
Bien que nous rencontrons plusieurs problèmes, par exemple, les méthode de traitement de données, la machine pour exécuter le projet. Avec l’aide de M.Gilles, ces problèmes sont résolues. Nous voulons remercier de l’aide de M.Gilles.